

脑部 MRI 图像分割实验报告

一、实验结果汇总

实验序号	实验配置	Best validation mean DSC
0	默认配置	0.914437
1	替换优化器为 AdamW	0.916495
2	增加学习率衰减余弦退火算法	0.917069
3	替换学习率衰减算法为 OneCycleLR	0.914469
4	修改随机数种子为 2025	0.888877
5	修改 UNet 结构	0.914701
6	改进损失函数	0.826666
7	再次改进损失函数	0.906157
8	同时改进损失函数和 UNet 结构	0.767166

二、实验结果分析


1. 基线实验介绍

基线模型在验证集上获得 0.914437 的 DSC 分数,这个成绩在医学图像分割领域属于中等偏上水平。考虑到仅使用 110 例患者数据,其中仅 10 例用于验证,这个性能已经体现了 UNet 架构在小样本医学数据上的强大泛化能力。该基线采用标准配置:Adam 优化器配合固定学习率、基础 Dice 损失、标准 UNet 架构。这些经典组件的组合为后续改进提供了可靠的对比基准。

2. 预测结果展示


选取编号相同的预测图片进行对比观察（由于实验 4 改变了随机数种子，预测图像与其余实验不一致）。


TCGA_HT_7879_19981009-10.png 在不同实验中的预测结果和真实结果（其中红色轮廓表示模型的预测值，绿色轮廓表示真实标签）。



观察到实验 0、实验 1、实验 2、实验 5 预测效果与真实标签较为接近，实验 3、实验 7 预测效果能发现部分有较大差异，实验 6、实验 8 预测效果明显较差。


TCGA_DU_7014_19860618-29.png 在不同实验中的预测结果和真实结果（其中红色轮廓表示模型的预测值，绿色轮廓表示真实标签）。






观察到实验 0、实验 1、实验 2、实验 3、实验 5、实验 7 预测效果与真实标签较为接近，实验 8 预测效果能稍大差异，实验 6 预测效果明显较差。

实验 4 预测图像单独展示。



TCGA_HT_A616_19991226-17.png



TCGA_CS_4941_19960909-12.png

总体来说预测存在肉眼可见的误差。

3. 实验改动介绍与结果分析

实验 1: 替换优化器为 AdamW

结果: $DSC = 0.916495 \uparrow$ (小幅上升, +0.2%)

结果分析:

权重衰减解耦: AdamW 将权重衰减从梯度更新中分离, 避免 L2 正则化与自适应学习率的耦合失效问题。

泛化能力提升: 更有效的正则化抑制了过拟合, 验证集性能小幅提升。

医学图像特性适配: 脑部 MRI 数据样本有限 (110 例), AdamW 的隐式正则化更适合小样本场景。

深入探讨:

Adam 到 AdamW 的替换看似微小, 实则触及深度学习优化的核心问题。传统 Adam 优化器将 L2 正则化集成在梯度更新公式中, 导致权重衰减与自适应学习率产生意外的交互效应。当某个参数的梯度持续较小时, Adam 的二阶动量会累积, 使得该参数的有效学习率变大, 此时 L2 正则化的惩罚力度反而被削弱, 形成正则化失效。AdamW 通过解耦设计彻底解决了这个问题。它将权重衰减作为独立项直接从参数中减去, 不经过梯度计算路径。这使得正则化效果不再依赖梯度统计量, 在整个训练过程中保持稳定的约束强度。对于本任务的小样本场景, 这种改进尤为关键。脑部 MRI 数据集仅有 100 例训练样本, 模型极易记忆训练集的特定噪声模式, AdamW 的稳定正则化有效抑制了这种过拟合倾向。

实验 2: 增加余弦退火学习率衰减

结果: DSC = 0.917069 ↑ (小幅上升, +0.3%)

结果分析:

平滑收敛路径: 余弦退火避免突然的学习率下降, 保持梯度更新稳定性。

逃离局部最优: 周期性学习率波动帮助模型探索更好的损失曲面区域。

精细调优阶段: 训练后期极小的学习率使模型在最优解附近精细震荡。

深入探讨:

余弦退火成为所有实验中的最优配置, 这个结果揭示了学习率动态调整在复杂优化问题中的关键作用。传统固定学习率面临两难困境: 过大导致后期震荡无法精细收敛, 过小则前期收敛缓慢且易陷入局部最优。余弦退火通过模拟退火算法的物理过程, 在整个训练周期内平滑地从初始学习率衰减至接近零, 形成渐进式探索利用转换。在训练前期, 相对较高的学习率使模型快速脱离随机初始化状态, 大步探索损失曲面的全局结构。此阶段模型能够跨越多个局部最优区域, 避免过早锁定在次优解。进入中期后, 学习率按余弦曲线下降, 下降速度逐渐放缓, 这种非线性衰减为模型提供了充足的时间在有潜力的区域深入搜索。关键的是后期阶段, 学习率降至极小值时, 模型参数更新变得极为谨慎, 这种微调机制能够在已发现的最优解附近进行精细震荡, 最大程度榨取该区域的性能潜力。对于脑部病变分割这类特征细腻的任务, 余弦退火的优势更加突出。病变边界的精确刻画需要模型在训练后期对边缘像素的分类阈值进行极精细的调整, 这要求学习率必须足够小以避免破坏已学到的稳定特征。同时, 余弦曲线的平滑性保证了优化过程的稳定性, 避免了阶梯式学习率衰减可能带来的性能突变。

实验 3: 替换学习率衰减为 OneCycleLR 策略

结果: DSC = 0.914469 ≈ (持平, +0.003%)

结果分析:

超参敏感性: OneCycleLR 需精心调整参数, 默认配置很可能不是最优。

训练动态不匹配: "先升后降"的学习率曲线可能不适合本任务。

病变区域小目标特性可能需要更稳定的学习过程。

深入探讨:

OneCycleLR 的失败具有启发性。该策略倡导“超收敛”训练范式: 在前 30% 的训练周期内快速提升学习率至峰值, 然后在剩 70% 周期内逐步降至极低水平。在本任务中性能与基线持平甚至略差。失败的根源在于策略假设与任务特性的错

配。OneCycleLR 的高学习率阶段依赖于“超收敛现象”：在正则化充分的前提下，高学习率能迫使模型快速跳出狭窄的局部最优，找到更宽广的全局解区域。然而，医学图像分割任务的优化曲面特性与通用视觉任务存在本质差异。脑部病变的形态高度多样，从弥散的小病灶到大面积坏死区域，这种多样性导致损失曲面呈现出复杂的多峰结构，且峰谷之间的过渡并不平滑。在这种复杂地形下，OneCycleLR 的高学习率阶段反而成为负担。当学习率快速攀升时，模型参数的大幅更新可能破坏已习得的病变边界特征，这些特征需要长期稳定的训练才能精确捕捉。更严重的问题在于，医学数据的小样本特性使得每个 batch 的梯度估计存在较大噪声，高学习率会放大这种噪声的影响，导致训练轨迹震荡剧烈。此外，OneCycleLR 对超参数的敏感性极高。峰值学习率、升温比例、退火策略等参数需要针对具体任务精心调校。

实验 4：修改随机种子为 2025

结果: $DSC = 0.888877 \downarrow (-2.8\%, \text{显著下降})$

结果分析:

数据划分影响: 随机种子直接决定训练/验证集的病例分配，种子变化可能导致验证集包含更多小病灶或困难样本。

样本代表性: 110 例患者中仅 10 例用于验证 (9%)，单个病例的特性差异会显著影响指标。

深入探讨:

仅仅改变随机种子就导致 DSC 下降近 3 个百分点，这个剧烈波动暴露了小样本医学数据集的脆弱性。表面上看，种子变化只是改变了训练集与验证集的具体划分，但这种看似无害的调整实际触发了连锁反应。核心问题在于验证集的极端小样本量。110 例患者中仅抽 10 例用于验证，意味着单个病例占验证集的 10% 权重。若某个病例恰好包含罕见的病变形态，则该病例的分割难度会显著高于平均水平。当随机种子将这类困难样本分配到验证集时，整体 DSC 必然大幅下降。相反，若验证集恰好包含大面积规则病变的简单病例，则 DSC 会虚高。更隐蔽的影响来自训练集的组成变化。假设原始种子下，训练集包含较多的小病灶样本，模型在训练过程中会学习到对微小异常的敏感检测能力。而新种子下，若这些小病灶样本被划分到验证集，训练集主要由大病变主导，模型会倾向于学习粗粒度的区域分割模式，导致在小病灶验证样本上表现糟糕。这种训练分布与验证分布的隐性偏移，是性能下降的深层原因。从统计学角度，10 例验证样本完全无法保证分布代表性。若进行多次随机抽样，验证集的平均病变面积、病变类型分布、图像质量等关键指标都会产生巨大波动。

实验 5：升级为 UNet++ 架构

结果: $DSC = 0.914701 \approx (\text{持平}, +0.03\%)$

结果分析:

密集跳跃连接未生效: UNet++ 的核心改进 (嵌套路径) 在此数据集上未体现优势。容量过剩问题: 参数量大幅增加 (约原 UNet 的 3 倍)，但 110 例训练样本不足以支撑更复杂的模型，过拟合风险上升，泛化能力未提升。

计算成本: 训练时间增加，但收益甚微。UNet++ 可能更适合大规模数据集。

深入探讨:

UNet++ 架构通过引入嵌套密集跳跃连接，重构了编码器-解码器间的特征融合机制，理论上能够增强多尺度语义信息的捕获能力。然而，在实验基于 110 例

脑部 MRI 数据的实验中，UNet++仅带来 0.03%的 DSC 提升（从 0.914437 至 0.914701），这一差异在统计学上不显著，可能源于训练过程的随机波动。究其根本，UNet++的参数量约为原始 UNet 的三倍，而有限的数据规模无法支撑其复杂结构的有效优化，反而引发容量过剩问题：模型倾向于记忆训练集噪声而非学习泛化特征。此外，密集连接虽丰富了特征组合，但在小样本条件下难以区分有益模式与无关变异，导致训练成本增加却未转化为实质性能增益。

实验 6：改进 Dice 损失函数（加权版本）

结果: DSC = 0.826666 ↓ (-9.6%，严重退化)

结果分析:

权重计算有误: 前景像素权重会导致数值爆炸（病变区域通常<5%像素）。

假阴性过度惩罚: 0.8 的 FN 权重使模型倾向"宁可错杀"，导致过分割。

边界惩罚不稳定: 梯度计算方式引入噪声，影响收敛。

小目标自适应失效: 阈值 0.01 过于严格，几乎所有切片都被加权，失去自适应性。

根本问题: 盲目堆砌多个组件而未验证单独有效性。

深入探讨:

本实验中，采用复杂加权 Dice 损失函数，融合类别加权、假阴性惩罚、边界感知及置信度正则化等多重机制，旨在提升脑部 MRI 图像分割性能。然而，该设计导致验证集 DSC 显著降至 0.826666，较基线（0.914437）下降 9.6%，暴露过度工程化的严重问题。具体而言，类别加权机制在病变像素占比极低（通常<5%）的医疗影像中产生 20-30 倍的权重差异，扭曲梯度信号平衡；假阴性惩罚项破坏 Dice 损失固有的召回率-精确率对称性，诱发过分割倾向；边界感知模块因一阶差分实现粗糙引入噪声，而置信度正则化的宽阈值限制模型对模糊边界的表达能力。各组件未经独立验证即整合，形成非线性交互的黑盒系统，加剧优化不稳定。对比其他实验配置（如 AdamW 优化器提升至 0.916495，余弦退火学习率调度达最高 0.917069），本次尝试凸显损失函数设计需遵循简约原则：在有限数据规模下，组件复杂度应与任务需求严格匹配，避免多重机制耦合导致的性能退化。

实验 7：采用 Dice+Focal 复合损失（均衡权重）

结果: DSC = 0.914469 ≈ (持平)

结果分析:

权重配比问题: 50:50 的配比使两种损失相互削弱，Dice 侧重区域重叠，Focal 侧重像素分类难度，二者目标存在一定冲突。

正面效果: Focal Loss 的难样本聚焦机制在边界像素上发挥作用。

深入探讨:

本实验揭示了 Dice 损失与 Focal 损失在 50:50 均衡权重配置下存在的内在优化冲突，导致脑部 MRI 分割性能下降约 1 个百分点。Dice 损失采用区域级整体主义视角，直接优化分割区域的重叠度，而 Focal 损失坚持像素级个体主义哲学，通过动态权重聚焦难分类样本，两者在优化目标上存在根本性差异。训练过程中，初期 Focal 损失因大量像素错误分类而退化为标准交叉熵，稀释了 Dice 损失的全局梯度信号；后期两者方向分歧加剧，Dice 倾向于维持整体轮廓，Focal 力图边界精修，引发优化拉锯。梯度尺度差异进一步导致信号干扰：Dice 梯度平滑稳定，Focal 梯度在预测置信度极端值时剧烈波动，造成优化轨迹震荡。此外，脑部 MRI 中病变区域占比仅 3-5%的极端类别不平衡放大了 Focal 损失对背景像素

的敏感度，干扰 Dice 损失的稳健性。

实验 8：同时采用 Dice+Focal 复合损失，并调整 DiceLoss 权重为 0.8 和改进的 UNet++ 结构

结果: $DSC = 0.767166 \downarrow$ (失败, -16.1%)

结果分析:

模块堆叠过度: 在实验 7 的基础上同时引入 4 种改进 (UNet++、深度可分离卷积、SimAM、残差连接)。

特征提取冗余: 7×7 深度卷积 + SimAM 注意力导致感受野过大, 丢失细节, 医学图像的病变边界需要精细的局部特征。

参数效率悖论: 深度可分离卷积减少参数, 但 SimAM 的能量计算增加前向传播时间。

注意力机制失配: SimAM 基于能量函数的全局统计, 可能不适合小病灶的局部特征增强。

训练不稳定: 多个模块的初始化和学习率需要精心调整。

深入探讨:

这次尝试集成深度可分离卷积、SimAM 注意力机制、UNet++ 架构及复合损失函数的脑部 MRI 分割实验, 其性能暴跌 16.1% 有多重原因, 核心应该是技术堆叠引发的系统性崩溃。首先, 深度可分离卷积虽提升参数效率, 却破坏多模态图像 (如 T1、T2、FLAIR 序列) 的跨通道空间协同, 导致关键病变特征提取能力退化; 7×7 大卷积核在通道隔离下进一步放大噪声, 削弱局部细节捕捉。其次, SimAM 注意力机制依赖全局能量统计, 系统性地忽视占比仅 2-5% 的小病灶, 与医学诊断需聚焦局部异常的需求根本冲突, 且与卷积缺陷形成恶性循环。UNet++ 的密集跳跃连接在小样本 (100 例) 下引发容量过载, 参数自由度过高导致过拟合, 而其复杂性与轻量化设计自相矛盾, 加剧架构不稳定。训练过程中, 多模块初始化策略冲突 (如残差连接需 He 初始化、SimAM 对数值范围敏感) 及梯度尺度混乱 (深度可分离卷积梯度大、SimAM 非线性波动), 导致优化器无法协调更新, 复合损失函数 (Dice+Focal) 的梯度差异进一步放大训练动态失控。这些缺陷环环相扣: 特征提取退化压制注意力有效性, 架构过拟合强化训练不稳定性, 最终引发连锁反应。