

滴滴出行-交通场景目标检测实验报告

1、实验汇总

实验	配置
默认配置	基于 MMDetection 框架的 Faster R-CNN 目标检测模型配置文件。通过继承四个基础配置模块来构建完整的训练体系。第一个模块是模型配置,使用 Faster R-CNN 作为检测算法,骨干网络采用 ResNet-50,并结合特征金字塔网络 FPN 进行多尺度特征提取。第二个模块是数据集配置,指定了滴滴检测数据集,并定义了训练、验证和测试数据的加载与预处理方式。第三个模块是训练计划配置,定义了学习率、优化器等训练超参数,对应个 epoch 的训练周期。第四个模块是运行时配置,负责日志输出、模型检查点保存等运行时的相关设置。
配置改进 1	在原有基础配置之上进行了多项修改。首先在训练循环配置中,将训练时长从默认的 12 个 epoch 扩展到 24 个 epoch,同时设置验证间隔为 1 表示每个 epoch 都进行一次验证。在优化器配置方面使用 AdamW 优化器替换了默认的 SGD 优化器,同时设定学习率为 0.0001 是一个相对保守的值便于稳定训练, betas 参数设置为 0.9 和 0.999 控制了动量和二阶矩估计,权重衰减设置为 0.05 用于正则化防止过拟合,此外还配置了梯度裁剪来限制梯度范数不超过 35。在学习率调度策略方面采用了两阶段方案,前 1000 次迭代使用线性预热将学习率从 0.001 倍逐渐升至正常值,之后的 24 个 epoch 使用余弦退火策略逐步降低学习率至 1e-8。
配置改进 2	针对默认配置进行了优化。该配置基于 ResNet-50 骨干网络和特征金字塔网络构建双阶段检测器,专门用于识别包括车辆、行人、非机动车和道路障碍物在内的十二类交通场景目标。图像预处理环节使用 ImageNet 预训练

	模型的标准归一化参数,将 BGR 格式转换为 RGB 格式,并设置填充尺寸为 32 的倍数以适配特征金字塔的多尺度特征提取。训练阶段的数据增强策略包括保持宽高比的图像缩以及随机水平翻转,这种设计在保证图像分辨率的同时增强了模型的泛化能力。模型架构方面,骨干网络采用深度为 50 层的 ResNet,冻结第一阶段的参数以保留低层特征的预训练知识,批归一化层设置为可训练但在推理时使用固定统计量。特征金字塔网络从骨干网络的四个不同阶段提取特征,输出通道统一为 256 维,并额外生成一个尺度的特征图以覆盖更大尺度的目标。区域提议网络使用三种宽高比的锚框配合单一尺度 8,在五个特征层级上生成候选区域,正负样本的 IoU 阈值分别设置为 0.7 和 0.3,采用 256 个样本的随机采样策略且正样本比例为 0.5。检测头部分使用双全连接层结构,中间层维度为 1024,RoI 特征提取采用 7x7 的 RoIAlign 操作,分类和回归任务分别优化交叉熵损失和 L1 损失,检测阶段每张图像保留最多 100 个检测框且分类得分阈值设为 0.05。训练策略相较基础版本进行了重要调整,优化器更换为 AdamW。学习率调度采用预热加多步衰减策略,前 500 次迭代进行线性预热,随后在第 8 和第 11 个 epoch 分别以 0.1 的因子衰减学习率,总训练周期为 12 个 epoch。评估体系包括 mAP、mAP50、mAP75 以及小中大目标 mAP 在内的多项指标,提议框数量设置为 100、300 和 1000 三档以评估不同召回率下的精度表现。测试集评估采用仅格式化输出模式,将预测结果保存为 COCO 标准格式。
配置改进 3	在基础的 Cascade R-CNN 实现多项修改。将检测器从 Faster R-CNN 升级为 Cascade R-CNN 三阶段级联结构,每个阶段采用不同的 IoU 阈值进行递进式优化,三个阶段的损失权重分别设置为 1、0.5 和 0.25。在骨干网络方面引入了可变形卷积 DCNv2 增强特征提

	取能力,除第一阶段外的后三个阶段都使用了可变形卷积,同时冻结第一阶段以保持底层特征的稳定性,并使用预训练的 ResNet50 权重进行初始化。针对数据集的类别不平衡问题进行了针对性处理,为 12 个检测类别设置了差异化的类别权重。在级联检测头的配置中,三个阶段使用了逐渐收紧的边界框编码标准差。RPN 网络采用了更密集的锚框配置,同时在训练时保留 2000 个候选区域,测试时保留 1000 个以平衡性能和效率。训练配置方面采用了 36 个 epoch 的长周期训练策略,每 2 个 epoch 进行一次验证,比标准配置增加了 3 倍的训练时长以充分学习数据特征。优化器配置采用 AdamW 替代传统 SGD。学习率调度采用两阶段策略,前 1500 次迭代进行线性预热从 0.001 倍逐渐升至正常值,随后 35 个 epoch 使用余弦退火策略将学习率从初始值逐步降至 $1e-8$。在数据处理方面,训练数据加载采用了长宽比批次采样器保证同批次图像尺寸相近,设置批次大小为 2 并启用持久化工作进程以加速数据加载,训练流程包括图像加载、标注加载、尺度变换、概率随机翻转等数据增强操作。评估指标整体 mAP、不同 IoU 阈值的 mAP 以及针对不同尺度目标的 mAP 指标,同时启用了逐类别统计功能便于分析各类别的检测性能。模型保存策略设置为每 2 个 epoch 保存一次检查点,根据验证集 mAP 自动保存最优模型。
配置改进 4	进行了多项修改,涵盖模型架构、类别权重、特征提取、损失函数和训练策略等多个方面。在骨干网络方面,将深度从 ResNet50 升级到 ResNet101。特征金字塔网络进行了改进,增加了额外的卷积层生成第 6 层金字塔输出。在锚框生成器配置中进行了调整,将长宽比从三种增加到四种,同时将尺度从五个层级减少到三个,扩大了步幅覆盖范围到 128。RPN 头的损失函数从简单的交叉熵损失升级为焦点损

	失。类别权重设置大幅提升。在 RPN 训练配置中，允许边界范围从 0 改为-1 表示不限制边界，同时 RPN 候选框的预筛选数量从 2000 增加到 3000。模型被设置为加载预训练权重，路径指向前面训练得到的最优检查点。优化器的学习率从 $1e-4$ 降低到 $5e-05$，骨干网络的学习率进一步降低到 0.05 倍，颈部网络设置为 0.5 倍，这种分层学习率能够在保持预训练骨干网络稳定的同时，允许检测头部快速适应新的数据特征。训练周期调整为 50 个 epoch，初始预热阶段的迭代次数从 1500 增加到 2000，余弦退火的周期相应调整到 49 个 epoch，最终学习率降至 $1e-07$。在推理阶段，RCNN 得分阈值从 0.05 降低到 0.01 用于检测更多候选目标，但最终输出的目标数量从 100 提升到 300。
--	---

2、数据集分析

数据集包含三个划分集合，其中训练集包含 10000 张图像和 82410 个标注实例,验证集包含 1000 张图像和 8608 个标注实例,测试集包含 1000 张图像但不提供标注信息。数据集涵盖 12 个目标类别,包括车辆类型如小汽车、面包车、公交车、卡车,交通参与者如行人、自行车、摩托车,以及特种车辆如三轮车、叉车和障碍物等。具体分布参考图 1 和图 2。




图 1 TRAIN 与 VAL 数据集中边界框尺寸等级分布特征




图2 交通场景目标检测数据集 TRAIN 与 VAL 数据划分类别统计分析

从图像特征分布来看,训练集图像平均尺寸为 1699×956 像素,标准差为 304×171 像素,尺寸范围在 1280×720 至 1920×1080 之间。验证集图像平均尺寸略大,为 1755×987 像素,标准差为 280×158 像素。测试集图像平均尺寸为 1726×971 像素,标准差为 294×165 像素。三个数据集的图像尺寸分布较为一致,均以高清分辨率为主,符合实际交通场景监控系统的图像采集标准。

标注密度分析显示,训练集平均每张图像包含 8.24 个标注目标,单张图像标注数量范围为 1 至 56 个,其中 127 张图像未包含任何标注目标。验证集平均每张图像包含 8.61 个标注目标,单张图像标注数量范围为 1 至 36 个,22 张图像无标注。这表明数据集整体标注密度适中,能够反映真实交通场景中目标数量的自然分布特征。

类别分布呈现显著的长尾特征。在训练集中,小汽车类别占据绝对主导地位,共有 52889 个实例,占总标注量的 64.18%。行人类别排名第二,包含 8314 个实例,占比 10.09%。卡车类别包含 6907 个实例,占比 8.38%。面包车和公交车分别包含 5418 个和 3547 个实例,占比分别为 6.57% 和 4.30%。自行车和摩托车等非机动车类别相对较少,分别为 2367 个和 1244 个实例。特种车辆和障碍物类别数量更为稀少,其中叉车类别仅有 35 个实例,占比 0.04%,为数据集中最稀缺的类别。验证集的类别分布与训练集保持高度一致性,小汽车类别同样占据 64.72% 的比例,各类别的相对比例关系基本保持稳定,但叉车类别在验证集中完全缺失。

边界框尺寸特征分析揭示了不同类别目标的显著几何差异。训练集中小汽车类别的平均边界框面积为 14267.4 平方像素,标准差为 35085.4,平均宽高比为 1.34,呈现横向矩形特征。公交车和卡车等大型车辆的平均边界框面积分别达到 32268.3 和 26337.5 平方像素,显著大于小型车辆。行人类别的平均边界框面积仅为 3388.1 平方像素,平均宽高比为 0.44,呈现典型的竖向矩形特征。障碍物类别具有最小的平均边界框面积,大型障碍物和小型障碍物的平均面积分别为 1705.7 和 1399.8 平方像素。叉车类别虽然样本量极少,但平均边界框面积达到 26752.8 平方像素,标准差高达 73114.3,显示出该类别目标尺度的高度可变性。

按照 COCO 标准将边界框划分为小型、中型和大型三个尺度等级。训练集中小型目标面积小于 1024 平方像素,共 23170 个实例,占比 28.12%。中型目标面积在 1024 至 9216 平方像素之间,共 38061 个实例,占比 46.18%,构成数据集的主体部分。大型目标面积大于 9216 平方像素,共 21179 个实例,占比 25.70%。验证集的尺度分布与训练集相近,小型、中型和大型目标的占比分别为 26.10%、45.77% 和 28.12%。边界框面积的中位数为 2709.1 平方像素,显著小于均值 14583.7 平方像素,进一步证实了数据分布的右偏特征。

类别不平衡问题在本数据集中表现突出。训练集中最多类别小汽车与最少类

别叉车的样本量比值达到 1511.11 比 1,这种极端的类别不平衡将对模型训练产生重要影响。除小汽车外,其余 11 个类别的总样本量仅占 35.82%,表明数据集存在严重的单类别主导现象。从训练集到验证集的类别分布一致性较好,但部分稀有类别如叉车在验证集中的缺失可能影响模型泛化性能的全面评估。

综合来看,小汽车类别的压倒性优势可能导致模型对该类别过度拟合,而叉车等极少数类别的训练样本严重不足将制约模型对这些类别的学习能力。需要针对类别不平衡问题采取数据增强、重采样或损失函数加权等策略,以提升模型在稀有类别上的检测性能,实现更加均衡和鲁棒的目标检测能力。

3、 部分实验结果展示和分析

category	mAP	mAP_50	mAP_75	mAP_s	mAP_m	mAP_l
car	0.594	0.821	0.667	0.329	0.602	0.781
van	0.354	0.477	0.411	0.136	0.294	0.57
bus	0.421	0.643	0.462	0.156	0.362	0.583
truck	0.421	0.612	0.465	0.116	0.415	0.53
person	0.266	0.599	0.191	0.138	0.316	0.376
bicycle	0.163	0.39	0.108	0.066	0.195	0.273
motorcycle	0.108	0.242	0.078	0.027	0.169	0.189
open-tricycle	0.283	0.509	0.29	0.26	0.308	0.324
closed-tricycle	0.232	0.366	0.256	0.067	0.269	0.202
forklift	nan	nan	nan	nan	nan	nan
large-block	0.104	0.305	0.052	0.035	0.206	nan
small-block	0.031	0.094	0.013	0.011	0.135	nan

图 3 配置 2 在 epoch_10 验证集指标

如图 3 所示,评估指标包括标准平均精度 mAP、IoU 阈值为 0.50 时的 mAP_50、IoU 阈值为 0.75 时的 mAP_75、小目标检测精度 mAP_s、中等目标检测精度 mAP_m 以及大目标检测精度 mAP_l。

从整体性能来看,小汽车类别在所有目标类别中表现最为优异,标准 mAP 达到 0.594,这与该类别在训练数据中占据绝对优势地位密切相关。在宽松的 IoU 阈值 0.50 条件下,小汽车的检测精度进一步提升至 0.821,但在严格的 IoU 阈值 0.75 条件下性能下降至 0.667,表明模型对小汽车目标的定位精度存在改进空间。面包车类别的整体 mAP 为 0.354,显著低于小汽车类别,但在 IoU 阈值 0.50 条件下仍能达到 0.477 的可接受水平。

大型车辆类别呈现出相对均衡的检测性能。公交车和卡车的标准 mAP 均为 0.421,在 mAP_50 指标下分别达到 0.643 和 0.612,显示出模型对这两类大型车辆具有较好的识别能力。然而在小目标检测场景下,公交车和卡车的性能急剧下降,mAP_s 分别仅为 0.156 和 0.116,这表明当大型车辆出现在图像远处或被遮挡时,模型的检测能力严重受限。相比之下,这两类车辆在中等尺度下的表现显著改善,mAP_m 分别达到 0.362 和 0.415,在大目标检测中进一步提升至 0.583 和 0.530。

行人类别作为交通场景中的重要目标,其标准 mAP 为 0.266,处于中等偏下水平。值得注意的是,行人在 IoU 阈值 0.50 条件下的检测精度达到 0.599,但在 0.75 阈值下骤降至 0.191,这一显著落差反映出模型对行人目标边界框的定位精度不足问题。从尺度敏感性分析来看,行人在小目标检测中的 mAP_s 为 0.138,在中等目标中提升至 0.316,在大目标中达到 0.376,呈现出随目标尺度增大而性能改善的趋势,但整体改善幅度相对有限。

非机动车类别的检测性能普遍低于机动车类别。自行车的标准 mAP 仅为 0.163,摩托车为 0.108,开放式三轮车为 0.283,封闭式三轮车为 0.232。在宽松的 IoU 阈值下,自行车和摩托车的检测精度分别提升至 0.390 和 0.242,但仍显著低于机动车类别。这些类别在小目标检测中表现尤为薄弱,自行车、摩托车和封闭式三轮车的 mAP_s 分别仅为 0.066、0.027 和 0.067,揭示出模型对小尺度非机动车目标的检测能力严重不足。开放式三轮车相对表现较好,其 mAP_s 达到 0.260,可能得益于该类别在训练数据中相对清晰的视觉特征。

特殊类别目标的检测结果展现出极端的性能分化现象。叉车类别在所有评估指标中均显示为缺失值,这直接归因于该类别在训练集中仅有 35 个样本且在验证集中完全缺失,导致模型无法有效学习该类别的视觉特征。障碍物类别同样面临严峻挑战,大型障碍物的标准 mAP 仅为 0.104,小型障碍物更是低至 0.031。在不同尺度下,大型障碍物的检测精度呈现先升后降的趋势,mAP₅₀ 为 0.305,mAP₇₅ 降至 0.052,小目标检测 mAP_s 为 0.035,中等目标 mAP_m 回升至 0.206,但大目标检测指标缺失。小型障碍物在所有尺度指标中均表现极差,mAP₅₀ 仅为 0.094,mAP₇₅ 为 0.013,小目标和中等目标检测精度分别为 0.011 和 0.135,大目标检测指标同样缺失。

从 IoU 阈值敏感性分析来看,绝大多数类别在从 0.50 阈值过渡到 0.75 阈值时都经历了显著的性能下降,平均下降幅度超过 30 个百分点。这一现象表明当前模型虽然具备较好的目标识别能力,但在精确定位方面仍存在明显不足,边界框回归精度有待提升。小汽车类别在该维度上的性能下降相对较小,从 0.821 降至 0.667,降幅约为 18.7%,而行人类别的降幅高达 68.1%,从 0.599 降至 0.191,反映出不同类别在定位精度上的显著差异。

尺度敏感性分析揭示了模型在处理不同尺度目标时的能力差异。小目标检测普遍成为性能瓶颈,除开放式三轮车的 mAP_s 达到 0.260 和小汽车的 0.329 外,其余类别的小目标检测精度均低于 0.2,其中摩托车的 0.027 和小型障碍物的 0.011 代表了模型在小尺度检测上的最低水平。中等尺度目标检测性能显著改善,小汽车、公交车和卡车的 mAP_m 分别达到 0.602、0.362 和 0.415,证明模型在中等尺度范围内具有较强的检测能力。大目标检测通常达到最优性能,小汽车和公交车的 mAP_l 分别高达 0.781 和 0.583,但部分类别如障碍物在大尺度指标上出现数据缺失,这可能是由于这些类别在验证集中缺乏足够的大尺度样本。

综合性能评估表明,在配置 2 的条件下,对主导类别如小汽车上取得了较为理想的检测效果,但在稀有类别、小目标检测和精确定位等方面存在明显短板。类别不平衡导致的训练偏向是造成这种性能分化的根本原因,叉车类别的完全失效和障碍物类别的极低精度直接反映了训练样本不足对模型学习能力的制约。未来改进方向应聚焦于通过数据增强、多尺度训练策略和针对性的损失函数设计来提升模型在稀有类别和小目标上的检测性能,同时需要加强边界框回归网络的设计以改善定位精度,最终实现更加均衡和鲁棒的全场景目标检测能力。



图 4 配置 2 预测图示例



图 5 配置 5 预测图示例

配置 2 基于 ResNet50 骨干网络和标准特征金字塔结构，采用三种宽高比锚框和 AdamW 优化器的 12 轮训练策略。该配置在图中展现出更均衡的目标检测能力，能够有效识别车辆、行人以及 small_block 等多类交通场景目标，特别是在小目标检测方面表现出色。这得益于其相对保守的模型设置和合理的训练周期安排，使得模型在学习过程中保持了较好的特征提取平衡。配置 4 虽然升级至 ResNet101 骨干网络并引入焦点损失函数与四种长宽比锚框，但在实际测试中出现了对小目标（如 small_block）的检测失败。这种性能下降可能源于过度的模型复杂化、分层学习率策略的不当设置或 50 轮较长训练周期导致的过度拟合。尽管配置 4 在某些超参数设置上进行了优化，但这些修改反而破坏了模型对多尺度目标的检测能力，导致其整体性能不如配置 2。因此配置 2 在实际应用中展现出了

更加稳健和可靠的检测效果。




图 6 配置 2 预测图片示例




图 7 配置 3 预测图片示例




图 8 配置 4 预测图片示例

4、 分析总结

从默认配置到配置 1 再到配置 4 的性能逐步下降现象，推测为目标检测模型优化过程中工程化不当导致的性能退化问题。

默认配置采用经典的 Faster R-CNN 架构配合 ResNet50 骨干网络，使用 SGD 优化器和标准的 12 轮训练周期，这种简洁的基线配置在多尺度目标检测任务中展现出良好的平衡性能。

配置 1 将训练周期从 12 轮扩展到 24 轮并引入 AdamW 优化器，虽然延长的训练时间理论上能够使模型更充分地学习数据特征，但过长的训练周期可能导致模型在验证集上过拟合，特别是结合余弦退火策略将学习率降至 $1e-8$ 的极低值时，模型容易陷入局部最优而失去对新样本的泛化能力。

配置 2 在配置 1 基础上调整了学习率调度策略，采用多步衰减替代余弦退火并将训练周期回调至 12 轮，这种修改在一定程度上缓解了过拟合问题，但 AdamW 优化器的自适应学习率特性在交通场景数据集的长尾分布下可能对罕见类别的学习产生负面影响。

配置 3 引入 Cascade R-CNN 三阶段级联结构和可变形卷积 DCNv2，并将训练周期进一步扩展到 36 轮，尽管级联结构能够递进式优化边界框预测精度，但三阶段检测头的引入显著增加了模型复杂度，在数据量有限的情况下容易导致各阶段之间的特征传递失衡，同时可变形卷积虽然增强了特征提取的灵活性，却也引入了额外的学习难度，使得模型在小目标检测上的稳定性下降。

配置 4 在配置 3 基础上进行了最激进的修改，将骨干网络升级至 ResNet101 并增加第六层金字塔输出，同时引入焦点损失和四种长宽比锚框，训练周期延长至 50 轮并采用分层学习率策略。

这一系列修改虽然在理论上能够提升模型的表达能力，但 ResNet101 的更深网络结构需要更大规模的数据集才能有效训练，否则容易出现梯度传播问题和特征退化现象。焦点损失的引入本意是解决类别不平衡问题，但在交通场景中 small_block 等小目标本身样本量就较少，过度抑制简单样本的梯度贡献反而削弱了模型对这些关键目标的学习能力。分层学习率策略将骨干网络学习率降至基础学习率的 0.05 倍，虽然保持了预训练权重的稳定性，但过低的学习率使得骨

干网络无法有效适应交通场景的特定特征分布，导致特征提取阶段就已经丢失了关键的小目标信息。

综合来看，性能退化的原因很可能在于模型复杂度的增加与训练策略的激进调整之间形成了恶性循环，更深的网络和更复杂的检测头需要更精细的训练策略和更大规模的数据支持，不当的学习率设置又加剧了过拟合风险，最终导致模型在 `small_block` 等小目标检测任务上完全失效。